

融合协同过滤与内容特征的电影推荐系统项目计划书

一、项目基本信息

项目名称：融合协同过滤与内容特征的电影推荐系统：多算法对比、可解释分析与交互式演示

英文题目：A Hybrid Movie Recommendation System with Collaborative Filtering and Content Features: Comparative Evaluation, Explainable Analysis, and Interactive Demonstration

项目方向：以选项 C 端到端应用系统开发为主，选项 B 算法系统性对比研究为重点支撑，选项 A 多源数据融合挖掘作为数据基础

团队规模：3 人

项目周期：3 周

团队成员：

角色	学号	姓名
组长	2353249	马源胜
组员	2351270	王天一
组员	2353408	周由

二、项目定位与研究意义

本项目以电影推荐为应用场景，构建一个端到端的数据挖掘系统。项目将融合用户评分行为数据、电影元数据、电影类型、用户标签、关键词和简介文本等多源信息，系统比较多种推荐算法在 Top-N 推荐任务中的表现，并进一步构建轻量级交互式推荐界面，用于展示推荐结果、模型对比、推荐解释和冷启动处理效果。

随着在线视频平台、流媒体服务和内容社区的发展，用户面对的电影、剧集和短视频数量迅速增长。如何从海量内容中为用户推荐符合其兴趣的电影，是推荐系统中的经典问题，也是数据挖掘在真实场景中的重要应用。传统推荐方法包括基于流行度的推荐、协同过滤、矩阵分解和基于内容的推荐等。不同方法在数据稀疏性、冷启动、可解释性和推荐多样性方面存在明显差异。因此，融合用户行为数据与电影内容特征，并系统比较不同推荐算法的效果，具有明确的研究价值和应用价值。

本项目的成果将包括可复现实验流程、多算法对比结果、消融实验、冷启动分析、推荐解释和可运行的 Streamlit 推荐系统 Demo，最终形成论文式项目报告与答辩展示材料。

三、研究问题

本项目围绕以下研究问题展开：

1. RQ1：不同类型推荐算法在电影推荐任务中的表现有何差异？

比较流行度推荐、User-Based CF、Item-Based CF、矩阵分解、基于内容的推荐和混合推荐方法，分析其在准确性、覆盖率和多样性方面的差异。

2. RQ2：融合电影内容特征是否能够提升推荐效果？

引入电影类型、标签、关键词和简介文本等内容信息，比较仅使用用户评分行为与融合内容特征后的推荐性能差异。

3. RQ3: 混合推荐方法能否缓解冷启动问题?

针对新用户或评分记录较少的用户, 设计基于类型偏好、喜欢电影和关键词输入的冷启动推荐方案, 分析内容特征在冷启动场景下的作用。

4. RQ4: 推荐结果是否具有可解释性?

从电影类型匹配、相似电影、用户历史偏好、关键词相似度和相似用户等角度解释推荐原因, 使系统不仅给出推荐结果, 还能说明推荐依据。

四、数据来源与数据说明

4.1 MovieLens 用户评分数据

MovieLens 是推荐系统研究中广泛使用的公开数据集, 包含用户对电影的评分记录。主要字段包括:

- ``userId``: 用户编号
- ``movieId``: 电影编号
- ``rating``: 用户评分
- ``timestamp``: 评分时间

该数据将作为协同过滤、矩阵分解和推荐评估的核心数据来源。核心开发阶段优先使用 MovieLens latest-small 或 MovieLens 1M, 以保证 3 周内稳定完成; 若进度允许, 再扩展到更大规模数据集。

4.2 MovieLens 电影元数据

MovieLens 数据中包含电影基础信息, 主要字段包括:

- ``movieId``: 电影编号
- ``title``: 电影标题
- ``genres``: 电影类型

该数据将用于构建基于内容的推荐特征, 并支撑推荐解释与系统展示。

4.3 用户标签与外部电影信息

MovieLens 的 ``tags.csv`` 可提供用户对电影添加的标签, ``links.csv`` 可用于关联 IMDb/TMDb ID。项目将优先使用 MovieLens 内部标签数据; 若时间允许, 将通过 TMDb 或公开电影元数据补充电影简介、关键词、演员、导演、发行年份、平均评分和海报链接等信息, 用于提升内容特征表达能力和系统展示效果。

五、任务定义与数据融合方案

本项目主要研究 Top-N

电影推荐任务。给定用户历史评分行为和电影内容信息, 系统需要为目标用户生成一个推荐电影列表。

输入:

- 用户历史评分记录
- 电影类型、标签、关键词、简介等内容特征
- 用户冷启动偏好输入, 如喜欢的类型、喜欢的电影或关键词

输出:

- Top-N 推荐电影列表
- 推荐得分
- 推荐理由
- 不同算法的性能对比结果

数据融合方案：

- 以 `userId` 和 `movieId` 为核心键融合评分、电影类型、用户标签和可选外部元数据。
- 基于评分数据构建用户-电影评分矩阵和隐式反馈矩阵。
- 将电影类型转化为 multi-hot 特征。
- 将标签、关键词和简介文本转化为 TF-IDF 特征。
- 构建用户画像、电影画像、训练集、测试集和推荐候选集。

六、总体技术路线

1. 数据获取与理解：下载 MovieLens 数据，整理评分、电影信息、标签和链接文件。
2. 数据清洗与格式统一：处理重复评分、低频用户、低频电影、异常评分和缺失字段。
3. 多源数据融合：融合评分行为、电影类型、标签和可选外部电影元数据。
4. 特征工程：构建用户-电影评分矩阵、电影类型特征、标签 TF-IDF 特征、流行度特征和用户画像。
5. 推荐算法实现：实现多种推荐算法并生成 Top-N 推荐列表。
6. 模型训练与参数调优：调整相似用户数量、相似电影数量、矩阵分解维度和混合推荐权重。
7. 多维度实验评估：计算准确性、覆盖率、多样性、热门偏置和冷启动指标。
8. 推荐解释分析：为推荐结果生成可解释说明。
9. Streamlit 交互界面开发：完成推荐演示、模型对比和可视化分析。
10. 项目报告、答辩 PPT 与演示材料整理。

七、算法设计与实验方案

7.1 推荐算法

模型编号	算法名称	类型	作用
M1	Popularity Baseline	基线方法	根据评分数量、平均评分或加权评分推荐热门电影
M2	User-Based Collaborative Filtering	协同过滤	根据相似用户历史偏好进行推荐
M3	Item-Based Collaborative Filtering	协同过滤	根据目标用户喜欢电影的相似电影进行推荐
M4	Matrix Factorization	隐因子模型	使用 SVD/ALS 学习用户和电影隐向量
M5	Content-Based Recommendation	内容推荐	基于电影类型、标签和文本特征计算内容相似度
M6	Hybrid Recommendation	混合推荐	融合协同过滤得分、内容相似度和流行度得分

混合推荐初步设计如下：

$$\text{Final Score} = \alpha * \text{Collaborative Filtering Score} + \beta * \text{Content Similarity Score} + \gamma * \text{Popularity Score}$$

其中 α 、 β 、 γ 为权重参数，项目将通过实验比较不同权重组合下的推荐效果。

7.2 冷启动策略

- 1. 新用户冷启动：用户选择喜欢的电影类型、标签或 3 部喜欢的电影，系统基于内容相似度和流行度生成初始推荐。
- 2. 新电影冷启动：对缺少评分的新电影，使用类型、标签、关键词和简介等内容特征计算相似电影。
- 3. 少评分用户：结合少量评分记录和内容偏好，使用混合推荐降低数据稀疏性影响。

7.3 数据划分

项目将采用训练集、验证集和测试集划分方式。为模拟真实推荐场景，可采用按时间划分或按用户留出部分高分电影的方式。对于每个用户，保留部分高分电影作为测试目标，用于检验模型是否能将 这些电影排在推荐列表前列。

7.4 对比实验

项目将比较 M1-M6 六类模型在 Top-N 推荐任务中的表现，并分析不同算法在准确性、覆盖率、多样性、热门偏置和冷启动场景中的差异。

7.5 消融实验

为分析不同数据源和特征的贡献，项目计划进行如下消融实验：

实验编号	实验设置	目的
A1	仅使用用户评分数据	检验行为数据效果
A2	仅使用电影类型特征	检验基础内容特征效果
A3	加入标签、关键词或简介文本	检验文本特征贡献
A4	协同过滤 + 内容特征	检验多源融合效果
A5	去除流行度项	分析流行度对推荐结果的影响

八、评估指标与结果分析计划

8.1 评价指标

评分预测指标：

- RMSE：均方根误差
- MAE：平均绝对误差

Top-N 推荐指标：

- Precision@K：推荐列表前 K 个电影中有多少是用户真正感兴趣的电影
- Recall@K：用户真正感兴趣的电影中有多少被成功推荐
- NDCG@K：考虑推荐排序位置的推荐质量指标
- MAP@K：衡量推荐列表整体排序质量
- Hit Rate@K：用户是否至少命中一个相关电影

推荐质量分析：

- Coverage: 推荐覆盖的电影范围，避免模型只推荐少数热门电影
- Diversity: 推荐列表内部的类型多样性
- Popularity Bias: 推荐结果对热门电影的偏向程度
- Case Study: 典型用户推荐结果与失败案例分析

8.2 结果分析计划

1. 主结果分析：使用表格和柱状图展示各模型在 Precision@K、Recall@K、NDCG@K 等指标上的表现。
2. 用户群体分析：按评分数量将用户划分为低活跃、中等活跃和高活跃用户，比较不同模型在不同用户群体上的表现。
3. 推荐多样性分析：比较不同算法推荐结果中的电影类型分布，分析热门偏置问题。
4. 错误案例分析：选取若干推荐失败案例，分析失败原因，如历史评分过少、类型标签过粗、热门电影偏置等。
5. 推荐解释分析：为典型推荐结果生成解释，例如“与用户高评分电影类型相似”“相似用户也喜欢该电影”“关键词与用户偏好匹配”等。

九、交互式系统设计

计划使用 Streamlit 构建轻量级交互式推荐系统，主要模块包括：

1. 用户选择模块：支持已有用户 ID、喜欢的电影类型、喜欢的电影、关键词和 Top-K 推荐数量选择。
2. 推荐结果模块：展示推荐电影标题、电影类型、推荐得分、推荐理由和可选海报/简介。
3. 冷启动推荐模块：面向新用户，根据类型偏好、喜欢电影或关键词生成推荐列表。
4. 模型对比模块：展示不同算法的 Precision@K、Recall@K、NDCG@K、Coverage 和 Diversity。
5. 可视化分析模块：展示用户兴趣画像、推荐结果类型分布、模型性能对比图和热门电影偏置分析。

该系统能够支持答辩现场演示：输入用户偏好，选择推荐算法，生成推荐列表，查看推荐理由，并比较不同模型效果。

十、代码结构设计

项目代码仓库采用模块化结构，便于分工开发、实验复现和最终演示。主要模块包括：

1. 数据目录：`data/raw/` 保存原始数据，`data/processed/` 保存清洗后的建模数据，`data/external/` 保存可选外部电影元数据。
2. 探索分析目录：`notebooks/` 保存数据理解、初步 EDA、基线实验和结果分析过程，便于记录实验思路。
3. 数据处理模块：`src/data/`
负责数据加载、缺失值处理、评分矩阵构建、电影类型特征提取和标签文本特征构建。
4. 推荐模型模块：`src/models/` 负责实现流行度推荐、User-Based CF、Item-Based CF、矩阵分解、内容推荐和混合推荐。
5. 评估模块：`src/evaluation/` 负责实现 Precision@K、Recall@K、NDCG@K、Coverage、Diversity 等指标，并统一输出模型对比结果。

6. 可视化与解释模块：`src/visualization/`
负责生成模型对比图、推荐结果分布图、热门偏置分析图和推荐解释文本。
7. 主流程模块：`src/pipeline.py` 与 `main.py`
串联数据处理、模型训练、推荐生成、评估和结果保存流程。
8. 交互系统模块：`app/streamlit\_app.py` 实现 Streamlit 推荐系统演示界面。
9. 交付材料目录：`reports/` 保存报告图表和实验表格，`slides/` 保存答辩材料，`README.md` 与 `requirements.txt` 提供运行说明和环境依赖。

十一、团队分工

成员	主要角色	具体职责	可考核输出
2353249 马源胜	组长；工程交付与混合推荐负责人	项目管理、仓库结构、完整 Pipeline、Streamlit 系统、混合推荐权重整合、README、PPT 统筹	`main.py`、`src/pipeline.py`、`app/streamlit_app.py`、`src/models/hybrid.py`、README、PPT、commit 记录
2351270 王天一	算法建模与冷启动负责人	实现 Popularity Baseline、User-Based CF、Item-Based CF、Matrix Factorization、Content-Based Recommendation；设计冷启动策略	`src/models/` 主要算法代码、训练脚本、冷启动模块、实验记录、方法章节
2353408 周由	数据工程与评估分析负责人	MovieLens/TMDb 数据处理、特征工程、训练测试划分、评价指标实现、消融实验、结果可视化和错误分析	`src/data/`、`src/evaluation/`、`src/visualization/` 代码、评估表格、分析章节

预计工作量比例：

成员	工作量比例
2353249 马源胜	34%
2351270 王天一	33%
2353408 周由	33%

十二、3 周进度安排

周次	主要任务	阶段成果
第 1 周	完成项目计划、仓库搭建、MovieLens 数据下载与清洗、评分矩阵构建、电影类型和标签特征构建、初步 EDA	项目计划书、仓库初始化、数据处理脚本、特征表、EDA 初图
第 2 周	实现 M1-M6 推荐算法；完成训练/测试划分、Top-N 推荐评估流程、初步消融实验和冷启动方案	推荐算法代码、评估代码、实验记录表、模型对比初稿
第 3 周	完成 Streamlit 系统、推荐解释模块、结果可视化、错误案例分析、项目报告、PPT、README 和最终演示准备	完整代码、项目报告、PPT、可运行系统、团队分工声明

十三、预期交付物

1. 项目计划书：包含项目背景、研究问题、数据来源、方法路线、团队分工和 3 周时间表。

- 2. 代码仓库: GitHub/Gitee 仓库, 包含完整 commit 历史, 每位组员均有贡献记录。
- 3. 完整代码: 模块化、有注释、可一键运行主流程。
- 4. 项目报告: 10-20 页, 论文格式, 包含摘要、引言、相关工作、方法、实验、讨论和结论。
- 5. 团队分工声明: 说明每个人完成的代码文件、报告章节、实验任务和工作量百分比。
- 6. 答辩 PPT: 10 分钟讲解与系统演示。
- 7. 项目海报: A0/A1 学术海报。

十四、范围控制与风险应对

风险	影响	应对方案
数据规模过大导致训练慢	影响模型调试和实验进度	先使用 latest-small 或 1M 数据完成主流程, 再按进度扩展数据规模
外部电影元数据匹配困难	影响内容特征和展示效果	优先使用 MovieLens 自带类型和标签信息; TMDb/IMDb 数据作为增强项
推荐评估实现复杂	影响模型对比	优先完成 Precision@K、Recall@K、NDCG@K, 再扩展 MAP@K、Coverage 和 Diversity
系统开发时间有限	影响演示效果	Streamlit 系统优先保证用户选择、推荐结果展示、推荐解释和模型对比图
冷启动评价主观性较强	影响报告说服力	设计模拟冷启动实验, 只保留用户少量评分或偏好输入进行评估

十五、预期创新点

- 1. 融合用户评分行为、电影类型、标签、关键词和简介文本等多源信息, 体现多源数据融合挖掘。
- 2. 系统比较至少 5 种推荐算法, 并进一步实现混合推荐。
- 3. 通过消融实验分析不同行为数据和内容特征对推荐性能的贡献。
- 4. 面向新用户和少评分用户设计冷启动推荐方案。
- 5. 为推荐结果提供可解释说明, 增强推荐系统透明度。
- 6. 使用 Streamlit 构建交互式系统, 完整呈现从数据到决策的推荐流程。