

融合协同过滤与内容特征的电影推荐系统

项目计划书

A Hybrid Movie Recommendation System with Collaborative Filtering and Content Features

项目定位：以端到端应用系统开发为主，融合多源数据、多算法系统性对比、可解释推荐与 Streamlit 交互式展示。
团队说明：本组实际为 3 人，将合并承担课程推荐的四类技术职责，并通过代码文件、实验记录、报告章节和 commit 记录提供可量化贡献证据。

团队成员：2353249 马源胜 2351270 王天一 2353408 周由

摘要

本项目面向电影推荐场景，构建一个融合用户评分行为与电影内容特征的端到端数据挖掘系统。项目将以 MovieLens 评分数据为核心，融合电影类型、用户标签以及可选的 TMDb/IMDb 电影元数据，完成数据清洗、特征工程、推荐模型训练、系统性算法对比、消融实验、冷启动分析和交互式系统展示。最终成果包括可复现实验代码、论文式项目报告、团队贡献声明、答辩 PPT 和 Streamlit 演示系统。

关键词：电影推荐；协同过滤；内容推荐；混合推荐；冷启动；数据挖掘

多源数据融合

融合评分行为、电影类型、用户标签与可选外部元数据。

多算法系统对比

比较流行度推荐、协同过滤、矩阵分解、内容推荐与混合推荐。

交互式成果展示

使用 Streamlit 展示推荐结果、模型对比、冷启动与推荐解释。

一、项目基本信息

项目	内容
项目名称	融合协同过滤与内容特征的电影推荐系统：多算法对比、可解释分析与交互式演示
项目方向	以端到端应用系统开发为主，结合多算法系统性对比与多源数据融合挖掘
团队规模	3 人。由于实际组队人数限制，本组以 3 人承担课程项目要求中的 4 类职责，并在最终报告中提供可量化贡献证据
项目周期	5 周，按课程项目周期组织；若实际执行时间较短，则优先完成核心数据管道、核心模型、核心评估和系统演示

二、选题背景与研究意义

随着在线视频平台和流媒体服务的发展，用户面对的电影与视频内容数量迅速增长。如何从海量内容中为用户推荐符合其兴趣的电影，是推荐系统和数据挖掘中的经典任务。传统推荐方法包括流行度推荐、协同过滤、矩阵分解和基于内容的推荐等，但不同方法在数据稀疏性、冷启动、推荐多样性和可解释性方面存在明显差异。

本项目希望围绕电影推荐任务，完成从数据获取、数据融合、特征工程、模型训练、实验评估到交互展示的完整流程。项目不仅关注模型准确率，还关注覆盖率、多样性、热门偏置、冷启动适应性和推荐解释，从而形成一个更接近真实数据科学团队工作的课程项目。

三、研究问题

- RQ1：不同类型推荐算法在电影推荐任务中的表现有何差异？比较流行度推荐、协同过滤、矩阵分解、基于内容的推荐和混合推荐方法在准确性、覆盖率和多样性方面的差异。
- RQ2：融合电影内容特征是否能够提升推荐效果？引入电影类型、用户标签、关键词和简介文本等内容信息，比较仅使用评分行为与融合内容特征后的推荐性能差异。
- RQ3：混合推荐方法能否缓解冷启动问题？针对新用户或少评分用户，设计基于类型偏好、喜欢电影和关键词输入的冷启动推荐方案。
- RQ4：推荐结果是否具有可解释性？从电影类型匹配、相似电影、相似用户、关键词相似度和用户历史偏好等角度解释推荐原因。

四、数据来源与多源融合方案

4.1 数据来源

- MovieLens 用户评分数据：包含 `userId`、`movieId`、`rating` 和 `timestamp`，作为协同过滤、矩阵分解和推荐评估的核心数据。
- MovieLens 电影元数据：包含 `movieId`、`title` 和 `genres`，用于构建电影内容特征和推荐解释。
- MovieLens 用户标签数据：`tags.csv` 提供用户对电影添加的自由文本标签，可用于构建标签 TF-IDF 特征。
- 可选外部电影信息：通过 `links.csv` 关联 IMDb/TMDb ID，并在时间允许时补充电影简介、关键词、演员、导演、发行年份、平均评分和海报链接等信息。

4.2 数据融合方案

- 以 `userId` 和 `movieId` 为核心键融合评分、电影类型、用户标签和可选外部元数据。
- 将电影类型转化为 `multi-hot` 内容特征，将标签、关键词和简介文本转化为 TF-IDF 文本特征。
- 构建用户-电影评分矩阵、隐式反馈矩阵、电影内容向量、用户兴趣画像和推荐候选集。
- 对外部元数据采用可插拔设计，保证没有外部数据时系统仍可完整运行。

五、任务定义

- 输入：用户历史评分记录、电影类型、标签文本、关键词、简介文本以及用户冷启动偏好输入。
- 输出：Top-N 推荐电影列表、推荐得分、推荐理由和不同算法的性能对比结果。
- 相关电影定义：在评估中，将评分 `rating` ≥ 4.0 的电影视为用户真正感兴趣的电影。

六、总体技术路线

1. 下载并整理 MovieLens 数据，完成数据理解和初步 EDA。
2. 进行数据清洗、缺失值处理和低频样本过滤。
3. 融合评分、电影类型、标签和可选外部元数据。
4. 构建评分矩阵、内容特征、流行度特征和用户画像。
5. 实现多类推荐算法并生成 Top-N 推荐结果。
6. 构造训练集、验证集和测试集，并计算推荐准确性、覆盖率、多样性和热门偏置指标。
7. 完成消融实验、冷启动实验、错误案例分析和 Streamlit 交互式推荐系统。

七、算法设计

编号	模型名称	类型	作用
M1	Popularity Baseline	基线方法	根据评分数量、平均评分或加权评分推荐热门电影
M2	Item-Based Collaborative Filtering	协同过滤	根据用户高分电影寻找相似电影并生成推荐
M3	User-Based Collaborative Filtering	协同过滤	根据相似用户的历史偏好生成推荐，作为扩展对比模型
M4	Matrix Factorization	隐因子模型	使用 SVD 或 ALS 学习用户和电影隐向量
M5	Content-Based Recommendation	内容推荐	基于电影类型、标签和文本特征计算内容相似度
M6	Hybrid Recommendation	混合推荐	融合协同过滤得分、内容相似度和流行度得分

混合推荐公式： $FinalScore = \alpha * CFScore + \beta * ContentScore + \gamma * PopularityScore$ 。项目将通过验证集比较不同权重组合，选择综合表现较好的混合推荐策略。

7.1 推荐解释生成策略

- 类型解释：推荐电影与用户高分电影具有相似类型。
- 相似电影解释：推荐电影与用户喜欢的电影在评分行为或内容向量上相似。
- 相似用户解释：相似用户也对该电影给出较高评分。
- 关键词解释：推荐电影的标签、关键词或简介文本与用户兴趣画像匹配。
- 质量解释：推荐电影在同类型候选集中具有较高评分或较高流行度。

八、实验设计

8.1 数据划分

- 对每个用户的评分记录按 timestamp 排序，保留后 20% 评分记录作为测试集，其余作为训练集。
- 若用户评分数量过少，则进行低频用户过滤或采用留一法。
- 测试集中评分 ≥ 4.0 的电影作为 relevant items，用于 Top-N 评估。

8.2 评价指标

层级	指标	说明
核心指标	Precision@10	推荐列表前 10 个电影中相关电影所占比例
核心指标	Recall@10	用户真正喜欢的电影中被推荐命中的比例
核心指标	NDCG@10	考虑排序位置的推荐质量指标
辅助指标	Coverage	推荐结果覆盖的电影范围
辅助指标	Diversity	推荐列表内部电影类型或内容的多样性
辅助指标	Popularity Bias	推荐结果对热门电影的偏向程度

8.3 消融实验

编号	实验设置	目的
A1	仅使用用户评分数据	检验行为数据的基础效果
A2	仅使用电影类型特征	检验基础内容特征效果
A3	加入用户标签、关键词或简介文本	检验文本特征贡献
A4	协同过滤 + 内容特征	检验多源融合效果
A5	去除流行度项	分析流行度对推荐结果的影响

8.4 冷启动实验

- 模拟少评分用户：对测试用户仅保留 1、3、5 条历史评分，比较 Item-CF、Content-Based 和 Hybrid 方法的 Recall@10 与 NDCG@10。
- 新用户偏好输入：用户在系统中选择喜欢的电影类型、关键词或 3 部喜欢的电影，系统基于内容相似度和流行度生成推荐结果。

8.5 结果分析计划

- 比较不同模型在低活跃、中活跃和高活跃用户群体上的表现。
- 分析不同模型推荐结果中的电影类型分布，观察是否存在热门电影集中推荐。
- 选取典型用户进行案例分析，解释模型推荐成功或失败的原因。
- 对 Hybrid 模型的权重参数进行敏感性分析，观察 alpha、beta、gamma 对结果的影响。
- 总结不同算法在准确性、覆盖率、多样性和冷启动适应性之间的取舍关系。

九、交互式系统设计

1. 用户推荐页面：选择已有用户 ID、推荐算法和 Top-K 数量，展示推荐结果。
2. 冷启动推荐页面：输入喜欢的类型、电影或关键词，生成新用户推荐列表。
3. 模型对比页面：展示 Precision@10、Recall@10、NDCG@10、Coverage 和 Diversity 的对比图。
4. 推荐解释页面：展示用户兴趣画像、推荐电影类型分布、热门偏置和推荐理由。

十、代码结构设计

- data/raw、data/processed、data/external：保存原始数据、处理后数据和外部元数据。
- src/data：负责数据加载、清洗、特征工程和评分矩阵构建。
- src/models：实现流行度推荐、协同过滤、矩阵分解、内容推荐和混合推荐。
- src/evaluation：实现 Precision@K、Recall@K、NDCG@K、Coverage 和 Diversity 等指标。
- src/visualization：生成模型对比图、推荐结果分布图、热门偏置分析图和推荐解释文本。
- app/streamlit_app.py：实现交互式推荐系统演示界面。
- main.py 与 src/pipeline.py：串联数据处理、模型训练、推荐生成、评估和结果保存流程。

十一、团队分工

成员	主要角色	具体职责	可考核输出
2353249 马源胜	组长；工程交付与混合推荐负责人	项目管理、仓库结构、完整 pipeline、Streamlit 系统、混合推荐权重整合、README、PPT 统筹	main.py、src/pipeline.py、app/streamlit_app.py、src/models/hybrid.py、README、PPT、commit 记录
2351270 王天一	算法建模与冷启动负责人	实现 Popularity、Item-CF、User-CF、Matrix Factorization、Content-Based Recommendation；设计冷启动策略	src/models 主要算法代码、冷启动模块、训练脚本、实验记录、方法章节
2353408 周由	数据工程与评估分析负责人	MovieLens/TMDb 数据处理、特征工程、训练测试划分、评价指标实现、消融实验、结果可视化和错误分析	src/data、src/evaluation、src/visualization 代码、评估表格、分析章节

预计工作量比例：马源胜 34%，王天一 33%，周由 33%。

十二、进度安排

周次	主要任务	阶段成果
第 1 周	完成项目计划、仓库搭建、MovieLens 数据下载与清洗、初步 EDA	项目计划书、仓库初始化、数据说明、EDA 图表
第 2 周	完成评分矩阵、电影类型特征、标签 TF-IDF 特征和基础数据管道	预处理代码、特征表、可复用数据加载模块
第 3 周	实现核心推荐模型和 Top-N 推荐评估流程	M1-M6 模型代码、评估代码、初步实验记录
第 4 周	完成消融实验、冷启动实验、错误案例分析和结果可视化	模型对比表、消融结果、冷启动结果、可视化图表
第 5 周	完成 Streamlit 系统、最终报告、PPT、README 和演示准备	完整代码、报告、PPT、团队分工声明、演示系统

十三、预期交付物

- 项目计划书：包含背景、研究问题、数据来源、方法路线、团队分工和时间计划。
- 代码仓库：GitHub/Gitee 仓库，包含完整 commit 历史。
- 完整代码：模块化、有注释、可一键运行主流程。
- 项目报告：10-20 页，采用论文格式，包含摘要、引言、方法、实验、讨论和结论。
- 团队分工声明：说明每位成员完成的代码文件、报告章节、实验任务和工作量比例。
- 答辩 PPT：10 分钟讲解与系统演示；可选加分项为 A0/A1 学术海报。

十四、风险分析与应对策略

风险	影响	应对策略
团队实际人数少于课程推荐人数	分工压力增大	合并职责并明确每人负责模块，用 commit、文件和章节证明贡献
数据规模过大导致训练慢	影响模型调试和实验进度	优先使用 latest-small 或 1M 数据集完成主流程，再视进度扩展规模
外部电影元数据匹配困难	影响内容特征和展示效果	优先使用 MovieLens 自带类型和标签；TMDb/IMDb 作为增强项
推荐评估实现复杂	影响模型对比完整性	优先完成 Precision@10、Recall@10 和 NDCG@10，再扩展其他指标
系统开发时间有限	影响演示效果	Streamlit 系统优先保证用户推荐、冷启动推荐、模型对比和推荐解释

十五、预期创新点

- 融合用户评分行为、电影类型、用户标签和可选外部文本信息，体现多源数据融合挖掘。
- 系统比较至少 5 种推荐算法，并进一步实现混合推荐。
- 通过消融实验分析行为数据和内容特征对推荐性能的贡献。
- 面向新用户和少评分用户设计冷启动推荐方案。
- 为推荐结果提供可解释说明，增强推荐系统透明度。
- 使用 Streamlit 构建交互式系统，完整呈现从数据到决策的推荐流程。

十六、质量控制与复现方案

- 使用统一的随机种子和固定的数据划分方案，保证不同模型在同一训练集和测试集上比较。
- 在 README 中明确环境依赖、数据下载方式、运行命令和输出文件路径。
- 将核心流程封装为 main.py 和 src/pipeline.py，支持一键运行主要实验。

- 保存模型评估结果、消融实验结果和冷启动实验结果，便于报告和答辩复查。
- 使用 Git 记录每位成员的代码贡献，并在最终团队分工声明中对应到文件、章节和实验任务。

十七、报告结构与展示计划

最终报告将采用论文式结构，预计包括摘要、引言、相关工作、数据与预处理、方法、实验设计、结果与分析、系统实现、讨论、结论和团队分工声明。答辩 PPT 将围绕“问题背景—数据融合—算法对比—实验结果—系统演示—总结反思”的逻辑展开。

演示环节计划展示三个核心流程：首先选择已有用户并生成推荐列表；其次模拟新用户冷启动并输入偏好；最后展示模型指标对比图、推荐解释和推荐类型分布。通过静态实验结果与动态系统演示结合，体现项目从数据到决策的完整流程。

十八、总结

本项目将构建一个融合协同过滤与内容特征的电影推荐系统，通过多源数据融合、多算法对比、消融实验、冷启动分析、推荐解释和交互式系统展示，完整呈现一个从数据到决策的数据挖掘应用流程。项目在实际 3 人团队条件下对职责进行合并分配，并通过明确的代码模块、实验记录和交付材料保证项目可执行、可评估和可复现。