

城市空气质量预测与异常污染检测系统项目计划书

一、项目基本信息

项目名称：城市空气质量预测与异常污染检测系统

项目方向：选项 A 多源数据融合挖掘 + 选项 B 算法系统性对比研究 + 选项 C 端到端应用系统开发

团队规模：3 人

项目周期：3 周

团队成员：

角色	学号	姓名
组长	2353249	马源胜
组员	2351270	王天一
组员	2353408	周由

二、项目背景与研究意义

空气污染会影响居民健康、城市交通、公共管理和环境治理。PM2.5、PM10、NO2、O3 等污染物浓度通常受到天气、季节、城市活动强度和突发事件等因素影响，具有明显的时间趋势、周期性和异常波动特征。

本项目拟融合空气质量、天气和日历特征等多源数据，构建一个城市空气质量预测与异常污染检测系统。项目将围绕一个主城市、一个核心污染物和一套完整可运行 Pipeline 展开，在此基础上实现多模型对比、异常检测和 Streamlit 交互展示，并视进度扩展到多城市、多污染物和深度学习模型。

三、研究问题

- 天气因素，如温度、湿度、风速、降水，是否会影响 PM2.5 等污染物浓度？
- 不同类型预测模型在空气质量预测任务上的表现有何差异？
- 异常检测算法能否识别污染物浓度异常升高的时间点？
- 如何通过交互式 Dashboard 展示空气质量趋势、预测结果、异常点和模型对比结果？

四、数据来源与数据融合方案

4.1 数据来源

- 空气质量数据：OpenAQ API

获取目标城市监测站点的 PM2.5、PM10、NO2、O3 等污染物浓度数据。核心版本优先选择 PM2.5 作为预测目标，保证任务聚焦。

- 天气数据：NOAA Climate Data Online API 或其他公开天气数据

获取目标城市对应时间段的温度、降水、风速、湿度等天气变量。

- 日历与节假日数据：Python 日期库或公开节假日数据

构造星期、月份、季节、是否周末、是否节假日等时间特征。

4. 备选城市与时间范围：

优先选择数据完整度较高的纽约、洛杉矶或伦敦。核心版本使用 2023 年至 2025 年的日级数据；若数据缺失较多，则缩短时间范围或更换城市。

4.2 数据融合方案

本项目将数据统一到日级时间粒度，以空气质量数据为主表，天气数据和日历特征作为外部特征，通过日期字段和城市/站点字段进行连接。融合后的建模表包含：

- 时间特征：日期、星期、月份、季节、是否周末、是否节假日
- 污染物特征：PM2.5、PM10、NO2、O3 等，核心目标为 PM2.5
- 天气特征：温度、湿度、风速、降水
- 滞后特征：前 1 天、前 3 天、前 7 天污染物浓度
- 目标变量：下一天或未来 7 天 PM2.5 浓度
- 异常标记：基于统计阈值或异常检测算法得到的异常点

五、技术路线

- 数据获取：编写 API 调用脚本，下载空气质量和天气数据，并保存为本地 CSV/Parquet 缓存。
- 数据清洗：处理缺失值、重复记录、单位差异、异常极值和日期格式问题。
- 数据融合：按日期合并空气质量、天气和日历特征，生成统一建模数据表。
- 探索性分析：分析 PM2.5 趋势、季节性、天气相关性和异常峰值。
- 预测建模：实现至少 5 种模型，包括基线模型、ARIMA/Prophet、Random Forest、XGBoost 和 LSTM 或替代模型。
- 异常检测：实现统计阈值、Isolation Forest、LOF、One-Class SVM 等方法。
- 模型评估：使用统一指标比较预测模型和异常检测方法，并进行误差分析。
- 系统展示：使用 Streamlit 构建交互式 Dashboard。
- 交付整理：完成项目报告、PPT、README 和演示材料。

六、算法设计与实验方案

6.1 预测模型

类型	算法	是否核心必做	作用
基线模型	Naive Forecast / Moving Average	是	提供最低性能参考
统计模型	ARIMA 或 SARIMA	是	建模趋势和周期性
时间序列模型	Prophet	是	建模趋势、季节性和节假日效应
机器学习	Random Forest	是	利用天气和滞后特征进行预测
机器学习	XGBoost	是	作为强基线模型进行对比
深度学习	LSTM	选做	若时间允许，用于建模长期依赖

6.2 异常检测模型

算法	是否核心必做	说明
Z-score / IQR	是	统计阈值方法，作为异常检测基线
Isolation Forest	是	基于随机切分的无监督异常检测
LOF	是	基于局部密度的异常检测
One-Class SVM	选做	学习正常样本边界，识别异常点

6.3 实验设计

预测任务采用按时间顺序划分训练集、验证集和测试集，避免未来信息泄漏。异常检测任务采用统计异常点、模型异常分数和典型案例分析结合的方式进行验证。所有模型使用统一数据集、统一指标和统一实验记录表，保证对比公平。

七、评估指标

预测任务指标：

- MAE：平均绝对误差
- RMSE：均方根误差
- MAPE：平均绝对百分比误差
- R²：拟合优度

异常检测指标：

- Precision、Recall、F1-score
- 异常点数量与时间分布
- 典型异常案例解释

工程交付指标：

- 主流程是否可一键运行
- Dashboard 是否支持交互展示
- README 是否包含环境配置、运行方式和模块说明
- GitHub/Gitee 是否具有清晰 commit 历史

八、交互式成果展示设计

计划使用 Streamlit 开发轻量级 Dashboard，核心页面包括：

1. 数据总览页：展示时间范围、记录数量、缺失情况和基础统计信息。
2. 趋势分析页：展示 PM2.5 历史趋势、季节变化和天气相关性。
3. 预测结果页：展示真实值与不同模型预测值的对比曲线。
4. 异常检测页：在时间序列图中高亮异常污染点，并展示异常原因分析。
5. 模型对比页：展示 MAE、RMSE、MAPE、F1 等指标排行榜。

九、团队分工

成员	主要角色	具体职责	可考核输出
2353249 马源胜	组长；工程与交付负责人；部分数据融合	项目管理、仓库规范、Pipeline 整合、Streamlit Dashboard、README、PPT 统筹、部分数据融合	`app/` 代码、`main.py`、README、PPT、演示材料、commit 记录
2351270 王天一	算法建模负责人	实现 ARIMA/Prophet、Random Forest、XGBoost、LSTM 或替代模型；维护实验记录	`models/` 代码、训练脚本、实验记录表、方法章节
2353408 周由	数据工程与评估分析负责人	API 数据获取、数据清洗、特征工程、异常检测、评估指标、结果可视化	`data_pipeline/`、`evaluation/` 代码、图表、评估分析章节

预计工作量比例：

成员	工作量比例
2353249 马源胜	35%
2351270 王天一	33%
2353408 周由	32%

十、3 周进度安排

周次	主要任务	阶段成果
第 1 周	完成选题计划、仓库搭建、数据源确认、数据下载、清洗融合、初步 EDA；确定主城市、时间范围和核心污染物	项目计划书、仓库初始化、数据获取脚本、融合数据表、EDA 初图
第 2 周	完成特征工程、预测模型和异常检测模型；至少完成 5 种预测/检测方法的可运行实验；统一评估指标	模型训练代码、异常检测代码、实验记录表、模型对比初稿
第 3 周	完成 Streamlit Dashboard、误差分析、报告、PPT、README 和最终演示准备；补齐 commit 记录和分工声明	完整代码、项目报告、PPT、可运行系统、团队分工声明

十一、预期交付物

- 1. 项目计划书：包含选题背景、数据来源、分工计划和 3 周时间表。
- 2. 代码仓库：GitHub/Gitee 仓库，包含完整 commit 历史，每位组员均有贡献记录。
- 3. 完整代码：模块化、有注释、可一键运行主流程。
- 4. 项目报告：10-20 页，论文格式，包含摘要、引言、方法、实验、讨论和结论。
- 5. 团队分工声明：说明每个人完成的代码文件、报告章节和工作量百分比。
- 6. 答辩 PPT：10 分钟讲解与系统演示。
- 7. 可选加分项：A0/A1 学术海报。

十二、范围控制与风险应对

风险	影响	应对方案
3 周周期较短	模型和系统开发时间紧	优先完成一个城市、一个核心污染物、一个完整 Pipeline
API 数据缺失或不稳定	影响数据完整性	提前缓存数据；准备备用城市；必要时使用公开 CSV 数据

风险	影响	应对方案
深度学习模型训练耗时	影响交付	LSTM 作为选做，核心对比以 ARIMA、Prophet、Random Forest、XGBoost 为主
异常检测缺少真实标签	影响客观评估	使用统计阈值构造弱标签，并结合典型案例解释
三人团队任务量大	影响质量	每周固定整合代码，优先保证可运行主流程和报告质量

十三、预期创新点

1. 融合空气质量、天气和日历多源数据，体现跨领域数据融合挖掘。
2. 在短周期内同时完成预测模型和异常检测模型对比。
3. 使用统一实验框架进行多算法比较，增强结果可信度。
4. 构建交互式 Dashboard，将模型结果转化为直观决策支持。